

Testes Metamórficos em LLMs

Classificação de Intenções em Atendimento ao Cliente

Fundamentos de Teste de Software

Agenda

1. 🎯 Problema e Motivação
2. 🔬 Testes Metamórficos — Conceito
3. 🛠️ Sistema Sob Teste (SUT)
4. 📊 Dataset e Transformações
5. 🧪 Experimento v1 — Resultados
6. ⚡ Experimento v2 — Refinamento
7. 🔍 Análise de Causa Raiz
8. ✅ Conclusões

1. O Problema

Testar LLMs é diferente de testar software convencional

Em software tradicional:

| *Input fixo → Output determinístico → Verificação direta*

Em sistemas LLM:

| *Input em linguagem natural → Resposta probabilística → **Oráculo é difícil de definir***

Como saber se o sistema é consistente?

2. Testes Metamórficos

"Se a intenção é a mesma, o rótulo deve ser o mesmo."

Em vez de verificar correção absoluta, verificamos **consistência** entre inputs relacionados.

Relação	Transformação	Exemplo
MR1	Paráfrase semântica	"Quero cancelar" $\approx$ "Preciso anular meu pedido"
MR2	Alteração de pontuação	"Quero cancelar." $\approx$ "Quero cancelar!"
MR3	Alteração de capitalização	"quero cancelar" $\approx$ "QUERO CANCELAR"

Uma **violação metamórfica** = rótulo da transformação $\neq$ rótulo da original.

3. Sistema Sob Teste

Configuração	Valor
Tarefa	Classificação single-label de intenções
Modelo	<code>claude-haiku-4-5</code>
Temperatura	<code>0</code> (determinístico)
Idioma	Português
Saída esperada	<code>{"label": "<classe>"}</code>

7 Classes de Classificação

`refund_request` · `cancel_order` · `delivery_problem` · `payment_issue`
`product_information` · `account_support` · `other`

3. Estratégias de Prompt

Estratégia	Descrição
<code>free</code> (Livre)	Instrução em linguagem natural, sem restrição de formato
<code>strict</code> (Estrito)	Exige retorno em JSON exato
<code>few_shot</code>	Instrução + exemplos de entrada/saída

Hipótese: `few_shot` produzirá saídas mais estáveis e consistentes.

4. Dataset e Transformações

Dataset Original

- **70 mensagens** em português
- **10 por classe** (distribuição balanceada)
- Validadas consensualmente por 2 integrantes do grupo

350 Transformações Geradas

Tipo	Quantidade
Paráfrases semânticas	210 (3 por mensagem)
Alteração de pontuação	70 (1 por mensagem)
Alteração de capitalização	70 (1 por mensagem)

4. v1 vs v2 — Qualidade das Paráfrases

v1 — Prefixo Mecânico (simplista)

"Preciso que a loja providencie o cancelamento, pois quero cancelar meu pedido."

- Prefixo fixo + frase original
- Palavras-chave fortes e repetitivas
- **Teste fácil demais para o modelo**

v2 — Geradas por IA (naturalísticas)

"Por favor, suspendam a transação que acabei de concluir."

- Vocabulário diverso, estrutura sintática variada
- Sem viés de palavras-chave repetitivas
- **Teste mais rigoroso e realista**

5. Escala de Execução

Experimento	Chamadas de API	Estratégias
v1 (3 prompts)	1.260	free + strict + few_shot
v2 (2 prompts)	840	strict + few_shot
Verificação de Non-Det.	378	Amostra de 10%, repetida 3x
TOTAL	2.478	—

Verificação de não-determinismo:

Com `temperature=0` → **0 variações** observadas em 378 execuções. O modelo é completamente determinístico.

5. Resultados v1 — Taxa de Violação

Estratégia	Violações	Total	Taxa
<code>few_shot</code>	7	350	2,0% ✓
<code>strict</code>	26	350	7,4% ⚠
<code>free</code>	350	350	100% ✗

Por que `free` falhou 100%?

O prompt livre retornou **texto explicativo**, nunca JSON.

O parser esperava `{"label": "..."} → todas as respostas foram inválidas.`

Lição: controle de formato de saída é parte essencial do design de sistemas LLM.

6. Comparação v1 vs v2 (sem free)

Métrica	v1	v2	Δ
Taxa de Violação Geral	4,71%	7,57%	+2,86%
Taxa de Flip de Predição	1,29%	3,00%	+1,71%
Saídas Inválidas (JSON)	0	0	—
Custo Total API	\$0.2087	\$0.2059	-\$0.003

O aumento de violações na v2 é um indicador positivo:

significa que o dataset v2 é mais rigoroso e eficiente em expor fragilidades reais.

6. Violações por Estratégia e Transformação (v2)

Por Estratégia

Estratégia	v1	v2	Δ
<code>few_shot</code>	2,0%	5,71%	+3,71%
<code>strict</code>	7,43%	9,43%	+2,0%

Por Tipo de Transformação

Transformação	v1	v2
Paráfrases	4,29%	7,86%
Pontuação	5,00%	6,43%
Capitalização	5,71%	7,86%

7. Causa Raiz 1 — Vulnerabilidade da Classe `other`

40 de 53 violações (75%) originam da categoria `other`.

Mensagem (rótulo: <code>other</code>)	Classificado como
"Qual o horário de atendimento?"	<code>account_support</code>
"Vocês têm parceria com outras empresas?"	<code>product_information</code>
"Gostaria de ver a política de privacidade."	<code>account_support</code>

Diagnóstico: A categoria `other` não tem fronteira semântica clara.

O LLM usa seu conhecimento geral para reclassificar em categorias mais específicas.

Recomendação: Subdividir `other` em subcategorias ou definir exemplos negativos no *prompt*.

7. Causa Raiz 2 — Desalinhamento Humano vs IA

10 violações (exclusivas da v2).

Ação do grupo: Reclassificamos `orig_other_005` de `other` → `account_support`:

| *"Gostaria de deixar uma sugestão para melhorar o aplicativo."*

Raciocínio humano: Sugestão sobre o app → interação com a conta → `account_support`.

Raciocínio do modelo: Feedback/sugestão genérica → `other`.

O modelo discordou sistematicamente da reclassificação.

| **Lição:** *Rótulos limítrofes têm subjetividade real. O LLM não é neutro — ele tem sua própria semântica implícita.*

7. Causa Raiz 3 — Gatilho de Vocabulário Financeiro

3 violações (`cancel_order` → `payment_issue`).

Paráfrases naturalísticas do v2 introduziram a palavra "**transação**":

*"Por favor, suspendam a **transação** que acabei de concluir."*

*"Preciso anular a **transação** que fiz no dia de hoje."*

O modelo associou "transação" → `payment_issue` em vez de `cancel_order`.

Diagnóstico: Palavras com forte apelo financeiro ativam associações semânticas dominantes no modelo, sobrepondo o contexto da frase.

Lição: A escolha lexical nas paráfrases influencia diretamente o resultado do teste.

7. Distribuição Consolidada das Falhas (v2)

Categoria da Violação	Causa Raiz	Ocorrências
<code>other</code> → <code>account_support</code>	Fronteira semântica fraca da classe <code>other</code>	30
<code>other</code> → <code>product_information</code>	Fronteira semântica fraca da classe <code>other</code>	10
<code>account_support</code> → <code>other</code>	Desalinhamento anotação humana vs IA	10
<code>cancel_order</code> → <code>payment_issue</code>	Gatilho de vocabulário financeiro	3
TOTAL		53

8. Conclusões

#	Conclusão
1	Testes metamórficos são eficazes para mapear fragilidades de LLMs
2	O design do prompt (<code>few_shot</code>) é crítico para saídas programáticas
3	Paráfrases realistas (v2) revelam ~61% mais violações que mecânicas (v1)
4	A classe <code>other</code> concentra 75% de todas as falhas em ambos os experimentos
5	Com <code>temperature=0</code> , o modelo é 100% determinístico

8. Recomendações para Produção

Recomendação	Impacto Esperado
Usar sempre <code>few_shot</code>	Menor taxa de violação, saídas sempre válidas
Subdividir a classe <code>other</code>	Eliminar até 75% das violações observadas
Incluir exemplos negativos no prompt	Melhor definição de fronteiras entre classes
Auditar vocabulário das paráfrases	Evitar gatilhos lexicais indesejados

8. Limitações do Estudo

- 📌 Dataset pequeno (70 mensagens originais)
- 📌 Domínio restrito: e-commerce em português
- 📌 Apenas `claude-haiku-4-5` avaliado
- 📌 Rótulo `other` tem subjetividade inerente na anotação

Trabalhos Futuros

- Avaliar outros modelos (GPT-4, Gemini, Llama)
- Expandir dataset com mensagens reais anonimizadas
- Aplicar em outros domínios (saúde, finanças, jurídico)
- Refinar a classe `other` em subcategorias

Obrigado!

Repositório do Projeto

[https://github.com/\[seu-usuario\]/fundamentos-de-testes](https://github.com/[seu-usuario]/fundamentos-de-testes)

Para replicar o experimento:

```
cp .env.example .env # configure ANTHROPIC_API_KEY
python scripts/generate_transformed_dataset.py --version all
PYTHONPATH=src python scripts/run_experiment.py --version v2 --dataset all
PYTHONPATH=src python scripts/analyze_experiments.py
```

Instruções completas em [docs/reproducao.md](#)

Fundamentos de Teste de Software — 2026