

Desenho Experimental e Plano de Coleta

Projeto: Avaliação de Testes Metamórficos em Sistemas Baseados em LLMs para Classificação de Intenções

Disciplina de Testes de Software

1. Contexto e objetivo do documento

Este documento consolida o desenho experimental e o plano de coleta definidos pelo grupo para o projeto da disciplina de Testes de Software. O projeto tem como tema técnicas de testes para sistemas baseados em Inteligência Artificial, com foco específico na avaliação de testes metamórficos em sistemas baseados em Large Language Models (LLMs).

O objetivo deste documento é tornar explícito o escopo do experimento, as decisões metodológicas, os dados que serão coletados, as métricas de avaliação e os critérios de análise. Dessa forma, ele poderá servir tanto como material de entrega para a professora quanto como guia interno para a execução do projeto pelo grupo.

2. Tema e enfoque do projeto

Tema escolhido: 10. Técnicas de testes para sistemas baseados em IA.

Título do projeto: Avaliação de Testes Metamórficos em Sistemas Baseados em LLMs para Classificação de Intenções.

Enfoque: estudo empírico exploratório e comparativo de estratégias de prompt em uma aplicação baseada em LLM.

O projeto avalia se um sistema baseado em LLM consegue manter consistência semântica ao classificar mensagens de clientes que expressam a mesma intenção de formas diferentes. Para isso, serão utilizadas relações metamórficas que verificam se transformações controladas na entrada preservam o rótulo esperado de classificação.

3. Sistema sob teste

O sistema sob teste será uma pequena aplicação de classificação de intenções baseada em LLM. A aplicação receberá uma mensagem textual de um cliente de e-commerce e deverá retornar exatamente um rótulo correspondente à intenção principal expressa na mensagem.

A aplicação não será apenas uma chamada direta ao modelo. Ela será estruturada como um pequeno sistema com template de prompt, cliente de API, parser de saída e executor de testes. Essa decisão aproxima o experimento de um cenário real de teste de software, no qual o

comportamento observado depende da interação entre prompt, modelo, parser e regras de validação.

- Domínio: atendimento ao cliente em e-commerce.
- Tarefa: classificação de intenções.
- Idioma: português.
- Tipo de classificação: single-label.
- Modelo: LLM via API, utilizando um modelo da família Claude.
- Configuração principal: temperature igual a 0 e limite baixo de tokens de saída.

4. Rótulos de classificação

Cada mensagem deverá ser classificada em exatamente um dos sete rótulos abaixo. O conjunto de rótulos será mantido igual em todas as estratégias de prompt para preservar o controle experimental.

Rótulo	Descrição
refund_request	Solicitação de reembolso ou devolução de dinheiro.
cancel_order	Solicitação de cancelamento de pedido ou compra.
delivery_problem	Problemas relacionados à entrega, atraso, rastreo ou recebimento.
payment_issue	Problemas relacionados a pagamento, cobrança, cartão, boleto ou PIX.
product_information	Dúvidas sobre características, disponibilidade, garantia ou detalhes de produto.
account_support	Problemas relacionados a conta, login, senha ou cadastro.
other	Mensagens que não se encaixam claramente nas categorias anteriores.

5. Dataset original

O dataset original será composto por 70 mensagens em português, distribuídas de forma balanceada entre os sete rótulos definidos. Assim, cada classe terá 10 exemplos originais.

As mensagens originais serão geradas com apoio de um LLM, mas passarão por revisão manual do grupo antes de serem utilizadas no experimento. Essa revisão tem como objetivo garantir que cada exemplo possua uma intenção principal clara e que o rótulo esperado esteja adequado.

Rótulo	Quantidade de mensagens originais
refund_request	10
cancel_order	10
delivery_problem	10
payment_issue	10

product_information	10
account_support	10
other	10
Total	70

As mensagens deverão variar em tamanho e estilo, incluindo frases curtas, médias e longas. Casos ambíguos serão evitados nesta etapa para que as violações detectadas possam ser interpretadas com maior confiabilidade.

6. Transformações metamórficas

Cada mensagem original será transformada de acordo com três tipos de transformação: paráfrase semântica, alteração de pontuação e alteração de capitalização. O objetivo é verificar se mudanças que deveriam preservar a intenção da mensagem mantêm o mesmo rótulo de classificação.

Tipo de transformação	Descrição	Exemplo
Paráfrase semântica	Reescrita da mensagem com outras palavras, preservando a mesma intenção.	"Quero meu dinheiro de volta" -> "Gostaria de solicitar reembolso da compra"
Pontuação	Alteração controlada da pontuação sem mudar o conteúdo semântico.	"Quero reembolso." -> "Quero reembolso!!!"
Capitalização	Alteração de caixa alta, caixa baixa ou combinações controladas.	"Quero reembolso" -> "QUERO REEMBOLSO"

A principal transformação do estudo será a paráfrase semântica, pois ela representa um problema recorrente em sistemas baseados em LLMs: usuários diferentes podem expressar a mesma intenção de formas distintas. As transformações de pontuação e capitalização serão utilizadas como relações secundárias de robustez.

7. Quantidade de casos de teste

O desenho experimental escolhido possui tamanho médio, buscando equilíbrio entre abrangência, custo de API e viabilidade de execução pelo grupo.

70 mensagens originais
3 paráfrases semânticas por mensagem = 210 casos transformados
1 transformação de pontuação por mensagem = 70 casos transformados
1 transformação de capitalização por mensagem = 70 casos transformados

Total de casos transformados = 350

Como o experimento comparará três estratégias de prompt, cada caso será executado em cada uma das estratégias.

70 mensagens originais x 3 prompts = 210 execuções originais
350 mensagens transformadas x 3 prompts = 1050 execuções transformadas

Total estimado = 1260 execuções

Além disso, 10% da base será repetida três vezes para verificar possíveis efeitos de não determinismo, mesmo com temperature configurada como 0.

8. Critérios de validação das paráfrases

As paráfrases serão geradas com apoio de um LLM e revisadas manualmente. O grupo adotará revisão por dois avaliadores, com discussão em caso de discordância. A paráfrase será aceita somente se cumprir todos os critérios abaixo:

1. Preservar a intenção original da mensagem.
2. Manter o mesmo rótulo esperado.
3. Não introduzir ambiguidade.
4. Não adicionar informações que mudem o sentido da mensagem.
5. Não remover informações essenciais da solicitação original.

Exemplo de paráfrase válida:

Original: "Quero cancelar meu pedido."

Paráfrase: "Gostaria de desistir da compra que fiz."

Rótulo esperado: cancel_order

Exemplo de paráfrase potencialmente inválida:

Original: "Quero cancelar meu pedido."

Paráfrase: "Quero cancelar meu pedido e pedir reembolso."

Motivo: a nova frase introduz uma segunda intenção.

9. Relações metamórficas

As relações metamórficas definem o comportamento esperado entre a entrada original e as entradas transformadas. O experimento adotará uma relação principal e duas relações secundárias.

Relação	Definição	Comportamento esperado
MR1 - Consistência semântica	Se duas entradas expressam a mesma intenção, o sistema deve retornar o mesmo rótulo.	A paráfrase deve receber o mesmo rótulo da mensagem original.
MR2 - Invariância à pontuação	Alterações de pontuação não devem mudar a intenção principal.	A mensagem com pontuação alterada deve manter o mesmo rótulo.
MR3 - Invariância à capitalização	Alterações de caixa alta ou caixa baixa não devem mudar a intenção principal.	A mensagem com capitalização alterada deve manter o mesmo rótulo.

10. Oráculos de teste

O experimento utilizará dois oráculos, reportados separadamente. Essa decisão permite avaliar tanto a corretude em relação ao rótulo esperado quanto a consistência interna do comportamento do LLM.

10.1 Oráculo principal: rótulo esperado humano

A saída do LLM será comparada com o rótulo esperado definido e validado pelo grupo. Uma violação ocorre quando a resposta parseada do modelo é diferente do rótulo esperado para aquele caso.

Rótulo esperado: refund_request
Saída do LLM: delivery_problem
Resultado: violação em relação ao rótulo esperado

10.2 Oráculo secundário: saída original do LLM

A saída obtida para a entrada transformada também será comparada com a saída obtida pelo LLM para a entrada original. Essa comparação permite medir mudanças de predição causadas pela transformação, mesmo quando a saída original do modelo já estava incorreta.

Entrada original: "Quero meu dinheiro de volta."
Saída original: refund_request

Entrada transformada: "Gostaria de receber reembolso pela compra."
Saída transformada: payment_issue

Resultado: prediction flip

11. Estratégias de prompt

O estudo comparará três estratégias de prompt: prompt livre, prompt estrito e prompt few-shot. Todas as estratégias utilizarão o mesmo conjunto de rótulos, permitindo uma comparação controlada.

11.1 Prompt livre

O prompt livre será mais natural e menos restritivo, simulando uma instrução simples para classificação.

Leia a mensagem do cliente e identifique qual é a intenção principal.

Mensagem:
"{mensagem}"

11.2 Prompt estrito

O prompt estrito exigirá que a resposta seja retornada em JSON, reduzindo problemas de interpretação e parsing.

Classifique a intenção da mensagem abaixo.

Retorne apenas um JSON no seguinte formato:
{"label": "um_dos_rotulos"}

Rótulos possíveis:
refund_request, cancel_order, delivery_problem, payment_issue,
product_information, account_support, other

Mensagem:

"{mensagem}"

11.3 Prompt few-shot

O prompt few-shot incluirá um exemplo fixo por rótulo, totalizando sete exemplos. Os exemplos serão os mesmos para todos os casos de teste, garantindo controle experimental.

Classifique a intenção da mensagem abaixo.

Rótulos possíveis:

refund_request, cancel_order, delivery_problem, payment_issue,
product_information, account_support, other

Exemplos:

"Quero meu dinheiro de volta." -> refund_request

"Gostaria de cancelar meu pedido." -> cancel_order

"Minha entrega ainda não chegou." -> delivery_problem

"Meu pagamento foi recusado." -> payment_issue

"Esse produto tem garantia?" -> product_information

"Não consigo acessar minha conta." -> account_support

"Obrigado pelo atendimento." -> other

Retorne apenas um JSON no seguinte formato:

```
{"label": "um_dos_rotulos"}
```

Mensagem:

"{mensagem}"

12. Configuração de execução da API

O modelo escolhido será acessado via API, utilizando um LLM da família Claude. O estudo usará apenas um modelo, pois o foco principal será comparar estratégias de prompt e tipos de transformação, e não diferentes famílias de modelos.

- Modelo: Claude via API.
- Quantidade de modelos: um modelo.
- Temperature: 0.
- Max tokens: baixo, pois a saída esperada é apenas um JSON curto.
- Política de erro: em caso de falha, repetir uma vez; se falhar novamente, marcar como erro.

Para cada execução, serão registrados metadados como nome do modelo, horário, parâmetros, estratégia de prompt, custo estimado e tempo de resposta.

13. Plano de coleta e armazenamento

Os dados serão armazenados em dois formatos: CSV para análise tabular e JSONL para preservação dos logs brutos. Essa estratégia permite tanto uma análise quantitativa simples quanto a auditoria posterior das respostas originais do modelo.

13.1 Campos coletados por execução

case_id

original_input_id
transformation_type
original_text
transformed_text
expected_label
prompt_strategy
prompt_text
model_name
parameters
raw_output
parsed_label
is_valid_output
is_violation_expected_label
is_prediction_flip
execution_time
estimated_cost
timestamp
manual_review_notes

13.2 Estrutura sugerida do repositório

```
llm-metamorphic-testing/  
├── data/  
│   ├── original/  
│   └── transformed/  
├── results/  
│   ├── raw/  
│   └── processed/  
├── notebooks/  
├── src/  
└── docs/
```

14. Métricas de avaliação

A métrica principal será a Metamorphic Violation Rate, que mede a proporção de casos transformados nos quais a relação metamórfica esperada foi violada.

Métrica	Descrição
Metamorphic Violation Rate	Proporção de casos transformados que violam a relação metamórfica esperada.
Prediction Flip Rate	Proporção de casos em que a predição da entrada transformada difere da predição da entrada original.
Invalid Output Rate	Proporção de respostas que não seguem o formato esperado ou não contêm um rótulo válido.
Violation Rate by Transformation Type	Taxa de violação separada por paráfrase, pontuação e capitalização.
Violation Rate by Prompt Strategy	Taxa de violação separada por prompt livre, estrito e few-shot.
Cost per Detected Violation	Custo de API necessário para detectar uma violação.
Average Response Time	Tempo médio de resposta por execução.

Token Usage	Quantidade de tokens utilizada por estratégia e no total.
Total API Cost	Custo total estimado da execução do experimento.

O custo por violação será calculado em duas perspectivas: global e por estratégia de prompt.

Custo por violação global = custo total da API / número total de violações detectadas

Custo por violação por estratégia = custo da estratégia / número de violações detectadas pela estratégia

15. Variáveis do experimento

Tipo de variável	Variáveis
Independentes	Estratégia de prompt; tipo de transformação.
Dependentes	Taxa de violação metamórfica; taxa de mudança de predição; taxa de saída inválida; custo; tempo de resposta.
Controladas	Mesmo modelo; mesma temperature; mesmo dataset; mesmos rótulos; mesmas transformações; mesmos parâmetros de API.

16. Cenários experimentais

O experimento será organizado em três cenários, cada um correspondente a uma estratégia de prompt.

Cenário	Descrição
Cenário 1	Execução com prompt livre.
Cenário 2	Execução com prompt estrito em JSON.
Cenário 3	Execução com prompt few-shot com sete exemplos fixos.

Todos os cenários serão executados sobre os mesmos inputs originais e transformados. Além disso, todos os tipos de transformação serão testados em todas as estratégias de prompt.

17. Plano de análise dos resultados

A análise combinará resultados quantitativos e inspeção qualitativa de falhas representativas. A parte quantitativa buscará comparar o desempenho das estratégias de prompt e dos tipos de transformação. A parte qualitativa buscará explicar exemplos concretos de comportamento inconsistente.

- Comparar a taxa de violação por estratégia de prompt.
- Comparar a taxa de violação por tipo de transformação.
- Comparar a taxa de saída inválida por estratégia de prompt.
- Comparar o custo por violação detectada.
- Analisar exemplos representativos de falhas.

Serão produzidas tabelas e gráficos com os seguintes recortes:

- Violation rate by prompt strategy.
- Violation rate by transformation type.
- Invalid output rate by prompt strategy.
- Cost per detected violation by prompt strategy.
- Representative failure examples.

Entre 10 e 20 violações representativas serão inspecionadas manualmente e categorizadas segundo os seguintes tipos:

- label confusion.
- formatting failure.
- semantic misunderstanding.
- over-sensitivity to wording.
- ambiguous input.
- paraphrase quality issue.

18. Ameaças à validade

O experimento apresenta algumas ameaças à validade que precisam ser reconhecidas e mitigadas durante a execução.

Ameaça	Mitigação planejada
Tamanho limitado do dataset	Utilizar distribuição balanceada e documentar a limitação no relatório.
Paráfrases podem alterar o sentido original	Realizar revisão manual por dois avaliadores e discutir discordâncias.
Subjetividade na validação manual	Definir critérios objetivos de aceitação e registrar observações dos revisores.
Mudanças na API ou versão do modelo	Registrar modelo, data, parâmetros e outputs brutos.
Custo de API pode limitar repetições	Manter desenho experimental de tamanho médio e repetir apenas 10% da base.
Não determinismo mesmo com temperature 0	Executar repetições em uma amostra da base e registrar variações.
Baixa generalização para outros domínios	Restringir conclusões ao domínio de e-commerce e indicar trabalhos futuros.

19. Divisão de trabalho sugerida

A divisão de trabalho será feita por fase do experimento, permitindo que as responsabilidades fiquem claras e que o progresso possa ser acompanhado em reuniões de check-in.

Fase	Responsabilidade
Dataset	Criar e revisar as 70 mensagens originais.
Transformações	Gerar e validar paráfrases, pontuação e capitalização.
Implementação	Criar cliente da API, templates de prompt, parser e executor de testes.

Análise	Calcular métricas, gerar tabelas e gráficos.
Escrita	Documentar metodologia, resultados, discussão e ameaças à validade.

20. Resumo executivo do desenho acordado

Domínio: atendimento ao cliente em e-commerce
 Tarefa: classificação de intenções
 Idioma: português
 Modelo: Claude via API
 Sistema: pequena aplicação com prompt template, parser e test runner
 Dataset: 70 mensagens originais
 Rótulos: 7 classes balanceadas
 Transformações: semântica, pontuação e capitalização
 Casos transformados: 350
 Estratégias comparadas: prompt livre, prompt estrito e prompt few-shot
 Total estimado: 1260 execuções
 Repetição para não determinismo: 10% da base, três vezes
 Métrica principal: Metamorphic Violation Rate
 Métricas adicionais: prediction flip rate, invalid output rate, custo, tempo e tokens
 Análise qualitativa: 10 a 20 violações representativas

21. Conclusão

O desenho experimental acordado permite avaliar, de forma controlada, a aplicabilidade de testes metamórficos em sistemas baseados em LLMs. Ao focar em classificação de intenções no domínio de e-commerce, o projeto se mantém viável, mensurável e conectado a um cenário prático de uso de IA em software.

A comparação entre prompt livre, prompt estrito e prompt few-shot permitirá observar se estratégias de prompt mais estruturadas reduzem violações metamórficas, mudanças indevidas de predição e saídas inválidas. Dessa forma, o experimento poderá gerar evidências úteis tanto para a disciplina de Testes de Software quanto para o desenvolvimento prático de aplicações baseadas em LLMs.